pgvector: capire le distanze

Spiegazioni semplici, esempi SQL e limiti pratici

La differenza fondamentale

Immagina un vettore come una freccia: ha una direzione e una lunghezza. Il coseno confronta la direzione; L2 confronta la posizione degli estremi; il prodotto interno combina allineamento e lunghezza. L1 somma gli scarti tra componenti. Sono criteri diversi e possono produrre classifiche diverse.

L2: distanza in linea retta

Operatore <->. Formula: radice della somma di (a_i - b_i)^2. Per A=(1,0) e B=(3,0), L2 vale 2: stessa direzione ma estremi diversi. L2 vale zero solo per vettori identici. Tiene conto della scala dei valori.

Coseno: direzione, non lunghezza

Operatore <=>. Distanza = 1 - (a · b)/(||a|| ||b||). Per A=(1,0) e B=(3,0), la distanza è zero: stessa direzione. Per vettori non nulli il valore è tra 0 e 2: 0 indica stessa direzione, 1 ortogonalità, 2 direzioni opposte. I vettori nulli non hanno una direzione definita.

Prodotto interno negativo

Operatore <#>. Il prodotto interno è la somma dei prodotti delle componenti; pgvector restituisce il suo negativo per consentire l'ordinamento crescente usato dagli indici. Rispetto ad A=(1,0), B=(3,0) ha prodotto interno 3 mentre C=(1,0) ha prodotto interno 1. Con <#>, B ottiene -3 e precede C, che ottiene -1. Non è una distanza geometrica in senso stretto.

L1: somma degli scarti

Operatore <+>. Formula: somma di |a_i - b_i|. Tra A=(0,0) e B=(3,4), L1 vale 7 e L2 vale 5. L1 accumula gli scarti linearmente; L2 dà maggiore peso relativo alle componenti con scarti grandi tramite i quadrati.

Distanze binarie

Hamming, <~>, conta i bit differenti: tra 1010 e 1001 vale 2. Jaccard, <%>, confronta le posizioni accese: distanza = 1 - intersezione/unione. Nell'esempio, l'intersezione ha una posizione e l'unione tre, quindi la distanza Jaccard è 2/3. Sono operatori per bit, non per i normali embedding float.

Vettori normalizzati

Normalizzare significa portare la lunghezza a 1. Per vettori unitari, L2 al quadrato = 2 × distanza coseno e <#> = distanza coseno - 1. Queste metriche producono quindi lo stesso ordinamento nella ricerca esatta. Indici approssimati possono comunque recuperare candidati differenti.

```
SELECT id, embedding <=> $1::vector AS distanza
FROM documenti
ORDER BY embedding <=> $1::vector
LIMIT 10;
```

Scelta pratica

Segui la metrica raccomandata dal modello e verifica i risultati sui tuoi dati. Non confrontare numericamente soglie di metriche diverse: 0,2 di coseno non equivale a 0,2 di L2. Un punteggio di similarità non è

automaticamente una probabilità di correttezza.

Fonte e ambito

Sintesi didattica degli argomenti discussi, basata sulla documentazione ufficiale di pgvector. I parametri mostrati non sostituiscono benchmark sui propri dati. Le funzioni disponibili dipendono dalla versione installata.

https://github.com/pgvector/pgvector/blob/master/README.md