pgvector: Filtering

Spiegazioni semplici, esempi SQL e limiti pratici

Che cosa significa

Filtering significa restringere i documenti ammessi usando WHERE: lingua, cliente, categoria, data o altre proprietà. Il filtro decide chi può partecipare alla risposta; la distanza vettoriale stabilisce l'ordine di rilevanza tra i candidati.

```
SELECT id, titolo
FROM documenti
WHERE lingua = 'it'
ORDER BY embedding <=> $1::vector
LIMIT 10;
```

Il problema degli indici approssimati

Quando il piano usa un indice vettoriale approssimato, il filtro viene applicato ai candidati trovati dalla scansione. Se molti candidati non rispettano WHERE, possono rimanere meno righe di quelle richieste. Questo descrive il funzionamento della scansione ANN, non l'ordine logico generale di esecuzione di ogni query SQL.

Un esempio

Se una scansione produce 40 candidati e soltanto il 10% rispetta il filtro, potresti ottenere circa 4 risultati: è una stima intuitiva, non una garanzia. LIMIT 10 impone un massimo, non obbliga il database a restituire dieci righe.

Strategia 1: indice sul filtro

Se il filtro è molto selettivo, PostgreSQL può usare un normale indice sulla colonna e poi calcolare esattamente le distanze sulle poche righe rimaste. Il planner sceglie in base ai costi stimati; verifica il piano, non presumere che combini automaticamente qualsiasi coppia di indici.

```
CREATE INDEX documenti_lingua_idx
ON documenti (lingua);

EXPLAIN (ANALYZE, BUFFERS)
SELECT id FROM documenti
WHERE lingua = 'it'
ORDER BY embedding <=> $1::vector
LIMIT 10;
```

Strategia 2: indice parziale

Un indice vettoriale parziale contiene soltanto un sottoinsieme. È utile per condizioni ricorrenti e pochi valori importanti. La query deve avere un predicato che il planner riconosca come compatibile con quello dell'indice.

```
CREATE INDEX documenti_it_hnsw
ON documenti USING hnsw (embedding vector_cosine_ops)
WHERE lingua = 'it';
```

Altre strategie

Le scansioni iterative esplorano ulteriori candidati quando il filtro elimina i primi. Il partizionamento può separare sottoinsiemi quando ha senso per il modello dati e per le query. Nessuna strategia è sempre migliore: valuta selettività, numero di gruppi, aggiornamenti e latenza.

Controllo operativo

Confronta quantità e qualità dei risultati con una ricerca esatta sul sottoinsieme filtrato. EXPLAIN ANALYZE esegue davvero la query: usalo consapevolmente su carichi di produzione.

Fonte e ambito

Sintesi didattica degli argomenti discussi, basata sulla documentazione ufficiale di pgvector. I parametri mostrati non sostituiscono benchmark sui propri dati. Le funzioni disponibili dipendono dalla versione installata.

https://github.com/pgvector/pgvector/blob/master/README.md