pgvector: HNSW e IVFFlat

Spiegazioni semplici, esempi SQL e limiti pratici

A cosa servono

HNSW e IVFFlat sono indici per la ricerca approssimata dei vicini. Riducono il lavoro rispetto al confronto con tutti i vettori, ma possono perdere alcuni dei veri risultati migliori. La metrica decide come confrontare due vettori; l'indice decide come cercarli efficientemente.

HNSW: una rete di collegamenti

HNSW costruisce un grafo multilivello. I livelli superiori facilitano spostamenti ampi; quelli inferiori affinano la ricerca tra vicini. In generale offre un migliore compromesso tra velocità e recall rispetto a IVFFlat, ma richiede più memoria e tempi di costruzione maggiori. Non richiede una fase di training e può essere creato su una tabella vuota.

```
CREATE INDEX documenti_hnsw
ON documenti USING hnsw (embedding vector_cosine_ops)
WITH (m = 16, ef_construction = 64);

SET hnsw.ef_search = 40;
```

I parametri di HNSW

m controlla il numero massimo di connessioni per livello; ef_construction la dimensione della lista dinamica dei candidati in costruzione. ef_search controlla la lista dei candidati in ricerca: aumentarlo tende a migliorare il recall, a costo di più lavoro. I valori mostrati sono un punto di partenza, non una taratura universale.

IVFFlat: gruppi di vettori

IVFFlat suddivide i vettori in liste tramite una fase di clustering. Per una query seleziona le liste più promettenti e confronta i vettori al loro interno. Costruisce generalmente più rapidamente e usa meno memoria di HNSW, ma ha un compromesso velocità/recall meno favorevole. Va creato dopo aver caricato dati rappresentativi.

```
CREATE INDEX documenti_ivfflat
ON documenti USING ivfflat (embedding vector_cosine_ops)
WITH (lists = 100);

SET ivfflat.probes = 10;
```

I parametri di IVFFlat

lists decide quanti gruppi costruire. probes decide quante liste esplorare per query. Aumentare probes migliora normalmente il recall e aumenta il costo. Se la distribuzione dei dati cambia molto, valuta se ricostruire l'indice con dati rappresentativi.

Come scegliere

Prova HNSW quando contano soprattutto latenza e recall e hai memoria disponibile. Valuta IVFFlat quando memoria e costo di costruzione pesano di più. Dover ricreare spesso un indice non è, da solo, un motivo per scegliere HNSW: la sua costruzione tende a essere più costosa.

Come misurare

Confronta le risposte con una ricerca esatta. Recall@10 significa: quanti dei veri dieci vicini migliori hai recuperato, diviso dieci. Misura anche latenza, memoria, spazio e comportamento con filtri realistici. Non creare entrambi gli indici senza uno scopo: aggiungono costi di spazio e aggiornamento.

Fonte e ambito

Sintesi didattica degli argomenti discussi, basata sulla documentazione ufficiale di pgvector. I parametri mostrati non sostituiscono benchmark sui propri dati. Le funzioni disponibili dipendono dalla versione installata.

https://github.com/pgvector/pgvector/blob/master/README.md