pgvector: tipi, operatori e contesto

Spiegazioni semplici, esempi SQL e limiti pratici

L’idea di base

pgvector è un’estensione di PostgreSQL che permette di salvare e confrontare vettori. Un embedding è una rappresentazione numerica prodotta da un modello: testi, immagini o altri oggetti vengono trasformati in sequenze di numeri. pgvector conserva e confronta questi numeri; non genera da solo gli embedding.

I tipi

vector(n): vettore denso con numeri a 32 bit, scelta standard. halfvec(n): vettore denso con numeri a 16 bit, più compatto ma meno preciso. sparsevec(n): rappresentazione che memorizza gli elementi non nulli, utile quando quasi tutte le componenti sono zero. bit(n): tipo binario di PostgreSQL, utilizzabile con le distanze binarie supportate da pgvector.

Cosa significa la dimensione

vector(768) indica un vettore con 768 componenti. La dimensione deve corrispondere all’output del modello. Avere la stessa dimensione non basta: gli embedding da confrontare devono appartenere a uno spazio compatibile, normalmente generato dallo stesso modello con la stessa configurazione.

```
CREATE EXTENSION IF NOT EXISTS vector;

CREATE TABLE documenti (
  id bigint GENERATED ALWAYS AS IDENTITY PRIMARY KEY,
  testo text,
  embedding vector(768)
);
```

Gli operatori di ricerca

<-> misura la distanza euclidea; <=> la distanza coseno; <#> il prodotto interno negativo; <+> la distanza Manhattan. Per bit, <~> misura Hamming e <%> Jaccard. Non tutti gli operatori sono applicabili a tutti i tipi. Per i vettori numerici sono disponibili anche operazioni come somma e sottrazione elemento per elemento.

```
SELECT id, testo
FROM documenti
ORDER BY embedding <=> $1::vector
LIMIT 10;
```

Il contesto corretto

Il parametro $1 contiene l’embedding della domanda, non il testo della domanda. Tipo, dimensione, modello e metrica devono essere coerenti. Se crei un indice per la distanza coseno su vector, usa vector_cosine_ops e interroga con <=>. Il parametro SQL è un segnaposto da valorizzare dal client, non un valore eseguibile da solo.

Attenzione ai limiti

I limiti di memorizzazione di un tipo e quelli di indicizzazione non coincidono necessariamente. Prima di progettare un indice verifica tipo, dimensioni e versione installata. “Vettore supportato” non significa automaticamente “indicizzabile con qualsiasi configurazione”.

Fonte e ambito

Sintesi didattica degli argomenti discussi, basata sulla documentazione ufficiale di pgvector. I parametri mostrati non sostituiscono benchmark sui propri dati. Le funzioni disponibili dipendono dalla versione installata.

https://github.com/pgvector/pgvector/blob/master/README.md